

応用統計学 最終レポート課題

以下の論文を読んで、課題 1, 2, 3 すべてに回答してください。

Gonzalez-Chica DA, Mnisi Z, Avery J, Duszynski K, Doust J, Tideman P, et al. (2016) Effect of Health Literacy on Quality of Life amongst Patients with Ischaemic Heart Disease in Australian General Practice. PLoS ONE 11(3): e0151079. <https://doi.org/10.1371/journal.pone.0151079>

本文や資料のオリジナル版は以下からダウンロードできます

<https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0151079>

課題 1: Table 2, Table 3 で用いられている二変量の関連性の検定の種類と、その検定が選択されている理由を各変数について説明してください。

課題 2: Table 4 の多変量モデルで投入されている変数を挙げ、論文ではその選択の根拠をどのように説明しているか記述してください。また、その選択の仕方が妥当であるか、根拠を示して説明してください。

課題 3: Table 2, Table 3, Table 4 について論文の記述を参考に同様の方法で分析を行い、各表と同じ統計量を算出し、表にまとめてください。Table 3 には追加で各カテゴリの度数も示してください。

注意

- 授業では扱っていない関数等を使わないと出せない結果もあります。自分でやり方を調べて結果を出してください。
- 授業で扱った方法や関数を用いなくても、コードが適切で、結果が正確に出ていれば問題ありません。
- 分析に必要な変数の多くは hl_qol.csv に作成済みです。論文本文と変数表を参照し、各表で使用する変数を特定してください。必要に応じて、カテゴリの順序指定、基準カテゴリの設定、Table 2 で用いる「inadequate health literacy vs others」などの派生変数を作成してください。ヘルスリテラシー合計点、SF-12 の各項目、個別の CVD 併存疾患・リスク因子は公開データに含まれていないため、それらを元データから再計算する必要はありません。
- 論文に記載されている方法で分析しても、論文に示されている結果と一致しない場合があります。特に、Table 2 は以下の指示どおりに集計すると各カテゴリの度数は一致せず、「inadequate health literacy」の割合、信頼区間も概ね近い値は出ますが、完全には一致しません。それ以外は論文に記載されている方法どおりに分析すればほぼ同じ値が出ます。
- Table 1 は配布データから作成することができませんので、無視してください。
- Table 2 はヘルスリテラシー(hlcatnew)が欠損のケースは除外して集計し、表を作成してください。
- Table 4 の年齢は連続量の方の変数(age)を使用してください。
- 図表や文章の言語は日本語、英語どちらでも結構です。
- 生成 AI、AI ツールは情報収集、疑問点を調べることに、コードが動かない場合などのデバッグの補助に使用して構いませんが、分析、コーディング、考察の主要部分は自身で行い、すべて自分で説明できるようにしてください。AI を使用した場合はどのような用途で使ったかを簡潔に記載してください。

配布ファイル

- ・ hl_qol.csv: ローデータ
- ・ 変数表.xlsx: ローデータ内の変数、カテゴリ一覧

提出物とファイル形式:

課題 1, 2 の記述: Word ファイル, PDF, テキストファイル

課題 3 の集計・分析のコード: .R 形式または.qmd 形式

課題 3 の結果表: Excel 等の表計算ソフトのファイル, Word ファイル, PDF

評価の観点

提出物は以下の観点で、合計 70 点満点で評価します。

評価観点(配点)	優れている	概ねできている	要改善
課題 1：検定の選択理由の説明 (14 点) 二変量検定の種類とその理由	Table 2・Table 3 の各変数について、用いられている検定の種類を正しく特定し、なぜその検定が適切かを、変数の性質（尺度の水準やカテゴリ数など）に基づいて説明できている。	概ね正しく説明できているが、一部の変数で種類の特定や理由の説明に不足・誤りがある。	検定の特定や理由の説明に誤りが多い。
課題 2：投入変数と選択根拠の記述・評価 (16 点) 多変量モデルの変数とその妥当性	各モデルに投入されている変数を正しく挙げ、論文がその選択をどのように根拠づけているかを正確に記述している。さらに、その選択の仕方が妥当かどうかを、根拠を示して自分の言葉で論じている。	変数の列挙や根拠の記述は概ねできているが、妥当性の検討が浅い、または一面的である。	投入変数の把握や根拠の記述に重大な誤りがある。
課題 3：データ準備・変数の操作化(8 点) 論文と変数表の読み取り／派生変数の作成	論文本文と変数表を読み込み、各表で使う変数を正しく特定している。必要な派生変数を論文の定義に沿って適切に作成している。	主要な変数は特定・作成できているが、一部の派生変数や設定に不足・誤りがある。	変数の特定や作成に誤りが多く、後続の分析が成立しない。
課題 3：分析の実装と結果(14 点) 分析の正しさ／結果の整合／有効サンプルの明記	各表の分析を正しく実装し、結果が論理的に整合している。論文と同じ方法で分析した表は論文の結果と妥当に対応している。各分析で実際に用いた有効サンプルサイズ（欠損を除いた人数）を明記している。	概ね整合するが、一部に説明のつかないずれがある、または有効サンプルサイズの記載がない。	多くの結果が再現できていない。
課題 3：結果表の表現 (8 点) 論文に準じた体裁・表記	論文と同じ形式で、変数名・単位・信頼区間や p 値などが明瞭に示され、読み手が理解しやすい。	必要な情報は揃っているが、体裁や表記に一部不備がある。	表として読み取りにくい、または成立していない。
コードの質と再現性 (10 点) 通し実行／可読性／判断の記録（課題 3 に適用）	提供された生データから最後まで通しで実行でき、処理の流れが整理され、要所に何をしているかを解説するコメントがある。変数の加工や分析の判断の過程を追うことができる。	実行できるが、整理やコメントに改善の余地がある。	そのままでは再現実行できない。